EVIDENCIAS

Arquitectura Medallion en Databricks

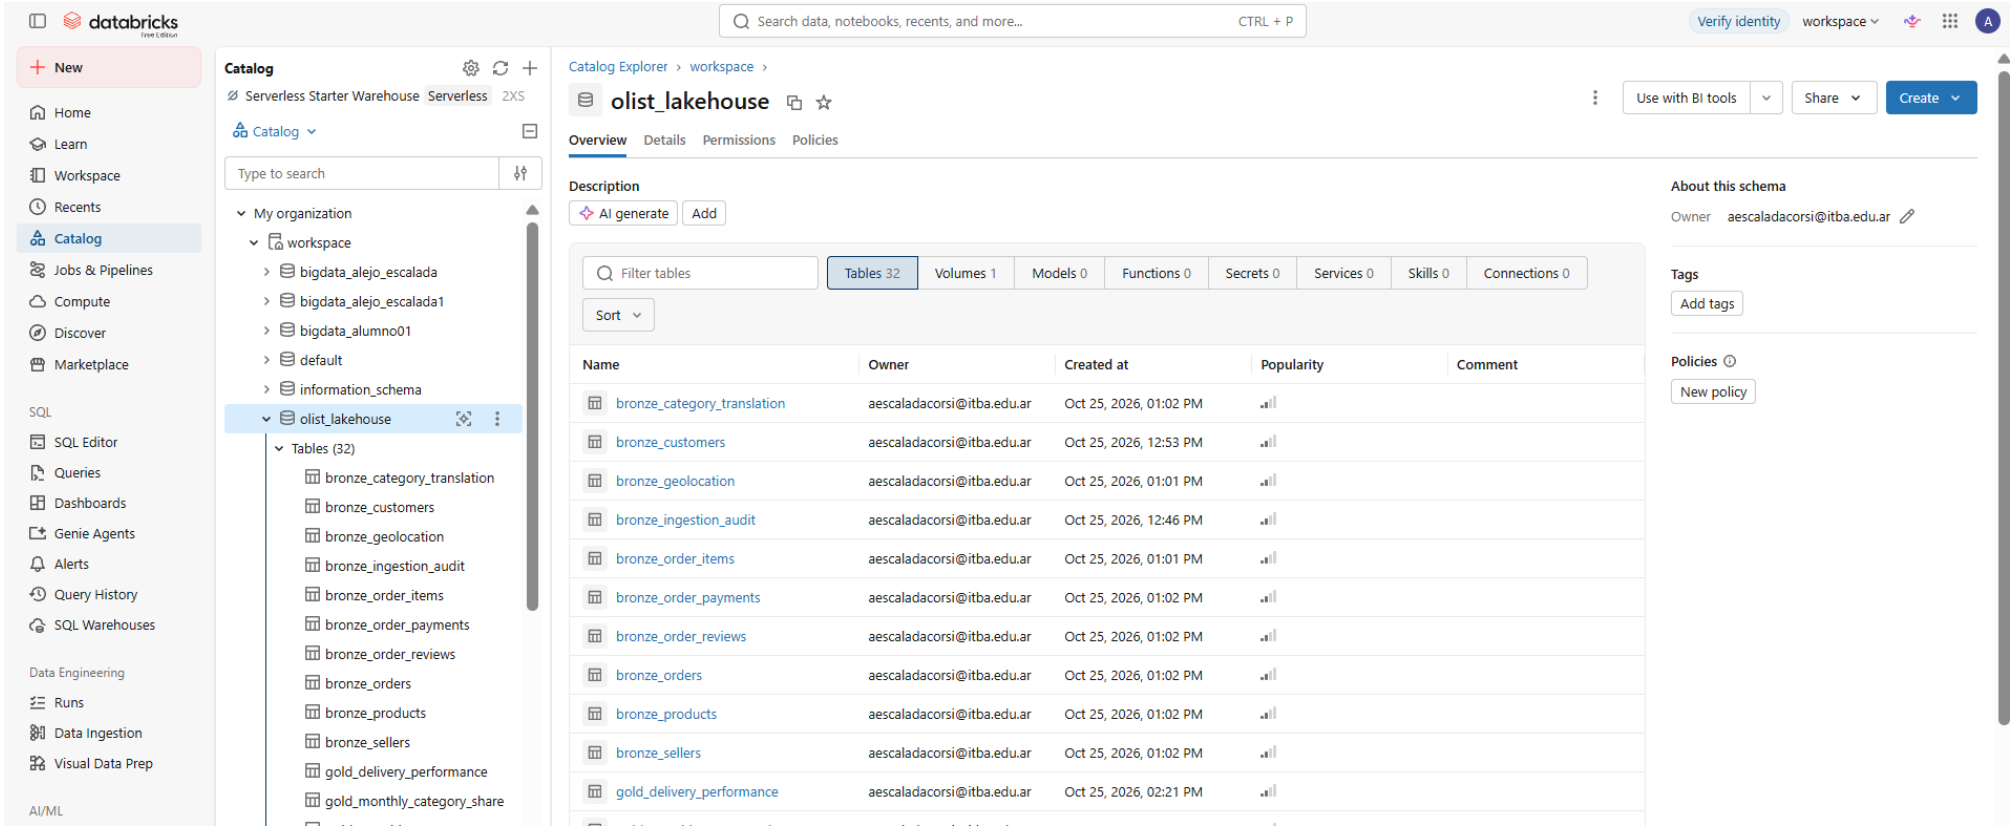
Trabajo práctico · Dataset Olist · Bronze / Silver / Gold

Alejo Escalada · 25 de octubre de 2026

Capturas de ejecución, calidad de datos, orquestación, idempotencia y visualizaciones analíticas.

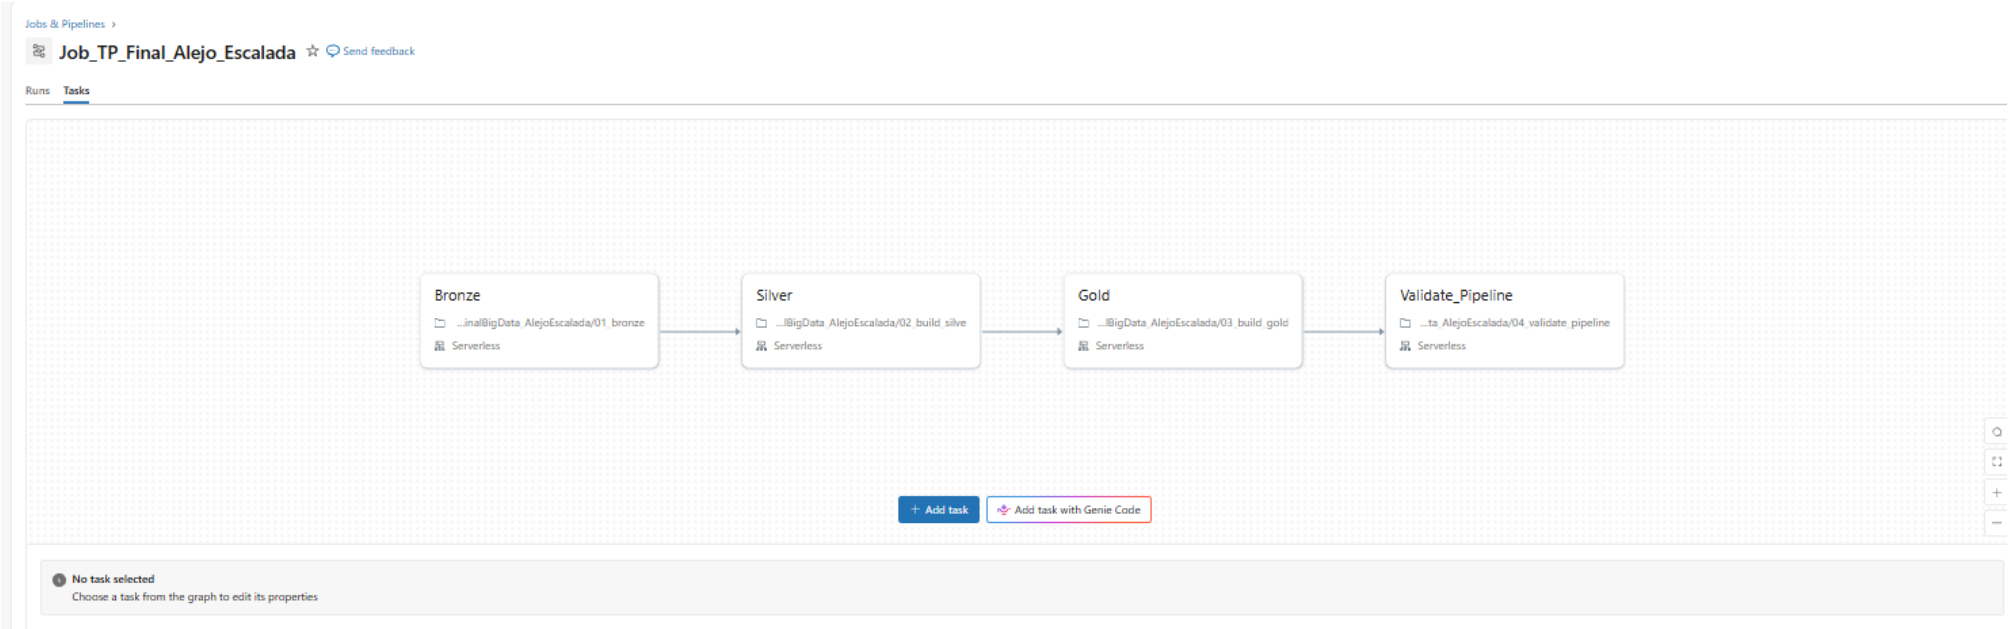
01 · Catálogo y arquitectura de datos

El esquema **workspace.olist_lakehouse** contiene 32 tablas. Se observa la organización de entidades Bronze y tablas Gold dentro del catálogo de Databricks.



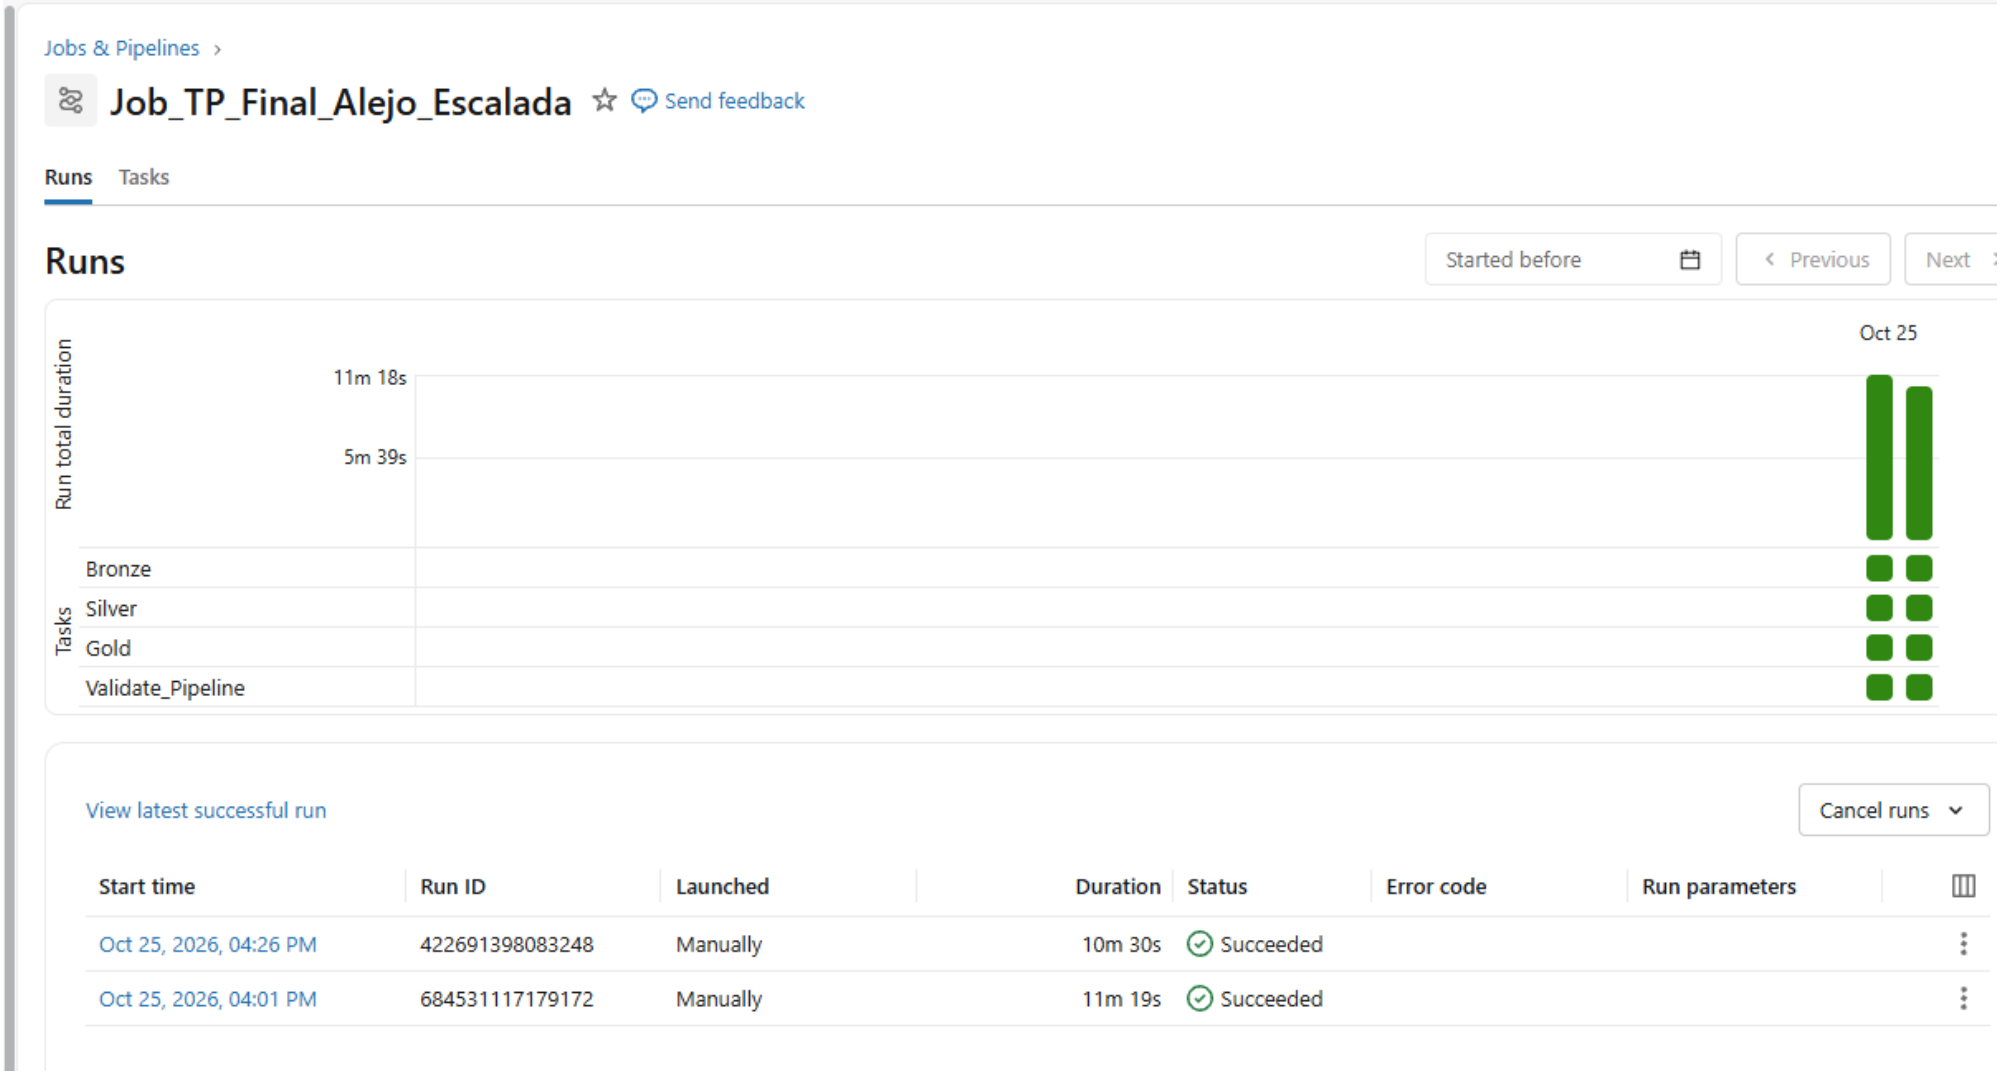
02 · Dependencias del Job

El Job **Job_TP_Final_Alejo_Escalada** define la secuencia **Bronze** → **Silver** → **Gold** → **Validate_Pipeline**, con dependencias explícitas entre tareas.



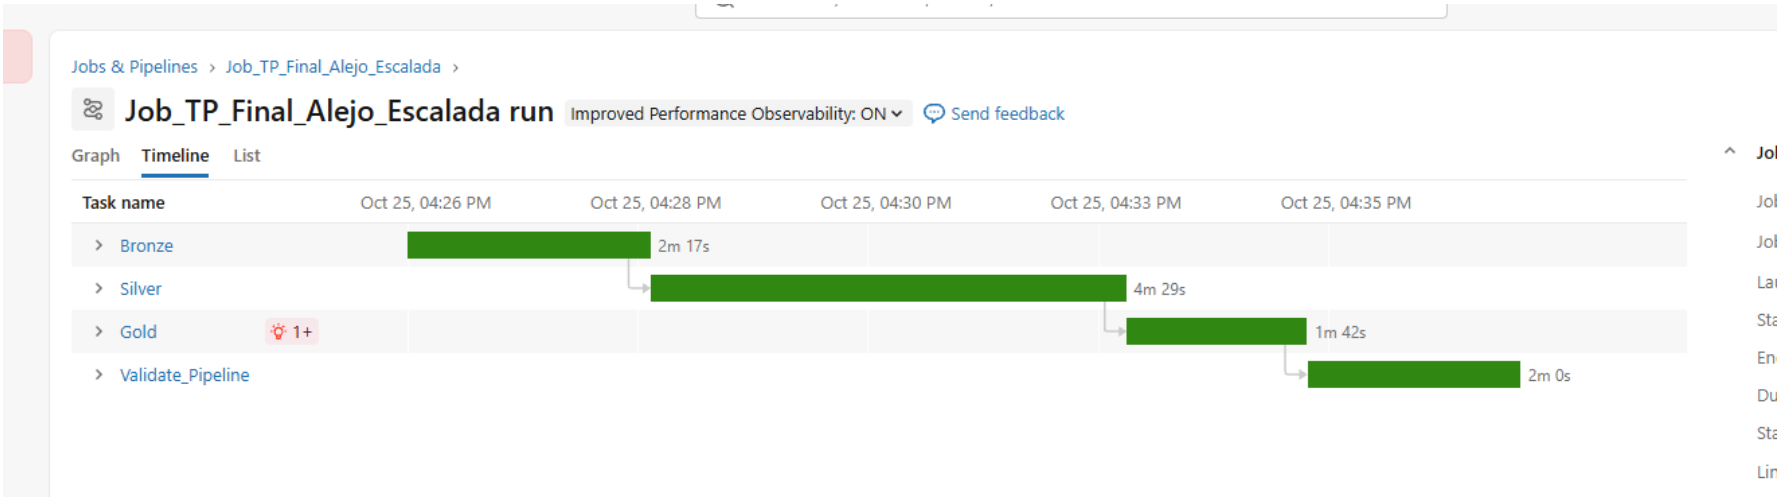
03 · Historial de ejecuciones

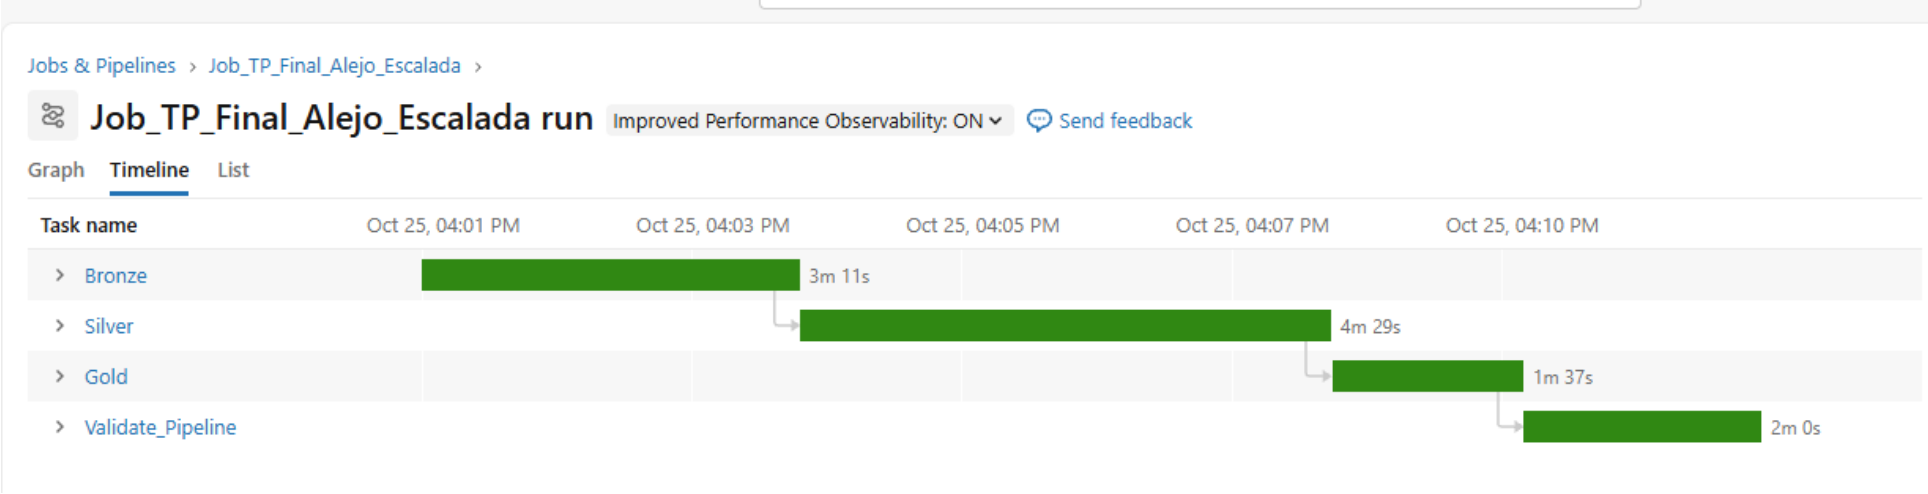
La interfaz del Job muestra dos ejecuciones manuales con estado **Succeeded**. Esto documenta que la orquestación completa se ejecutó exitosamente más de una vez.



04 · Secuencia temporal de las tareas

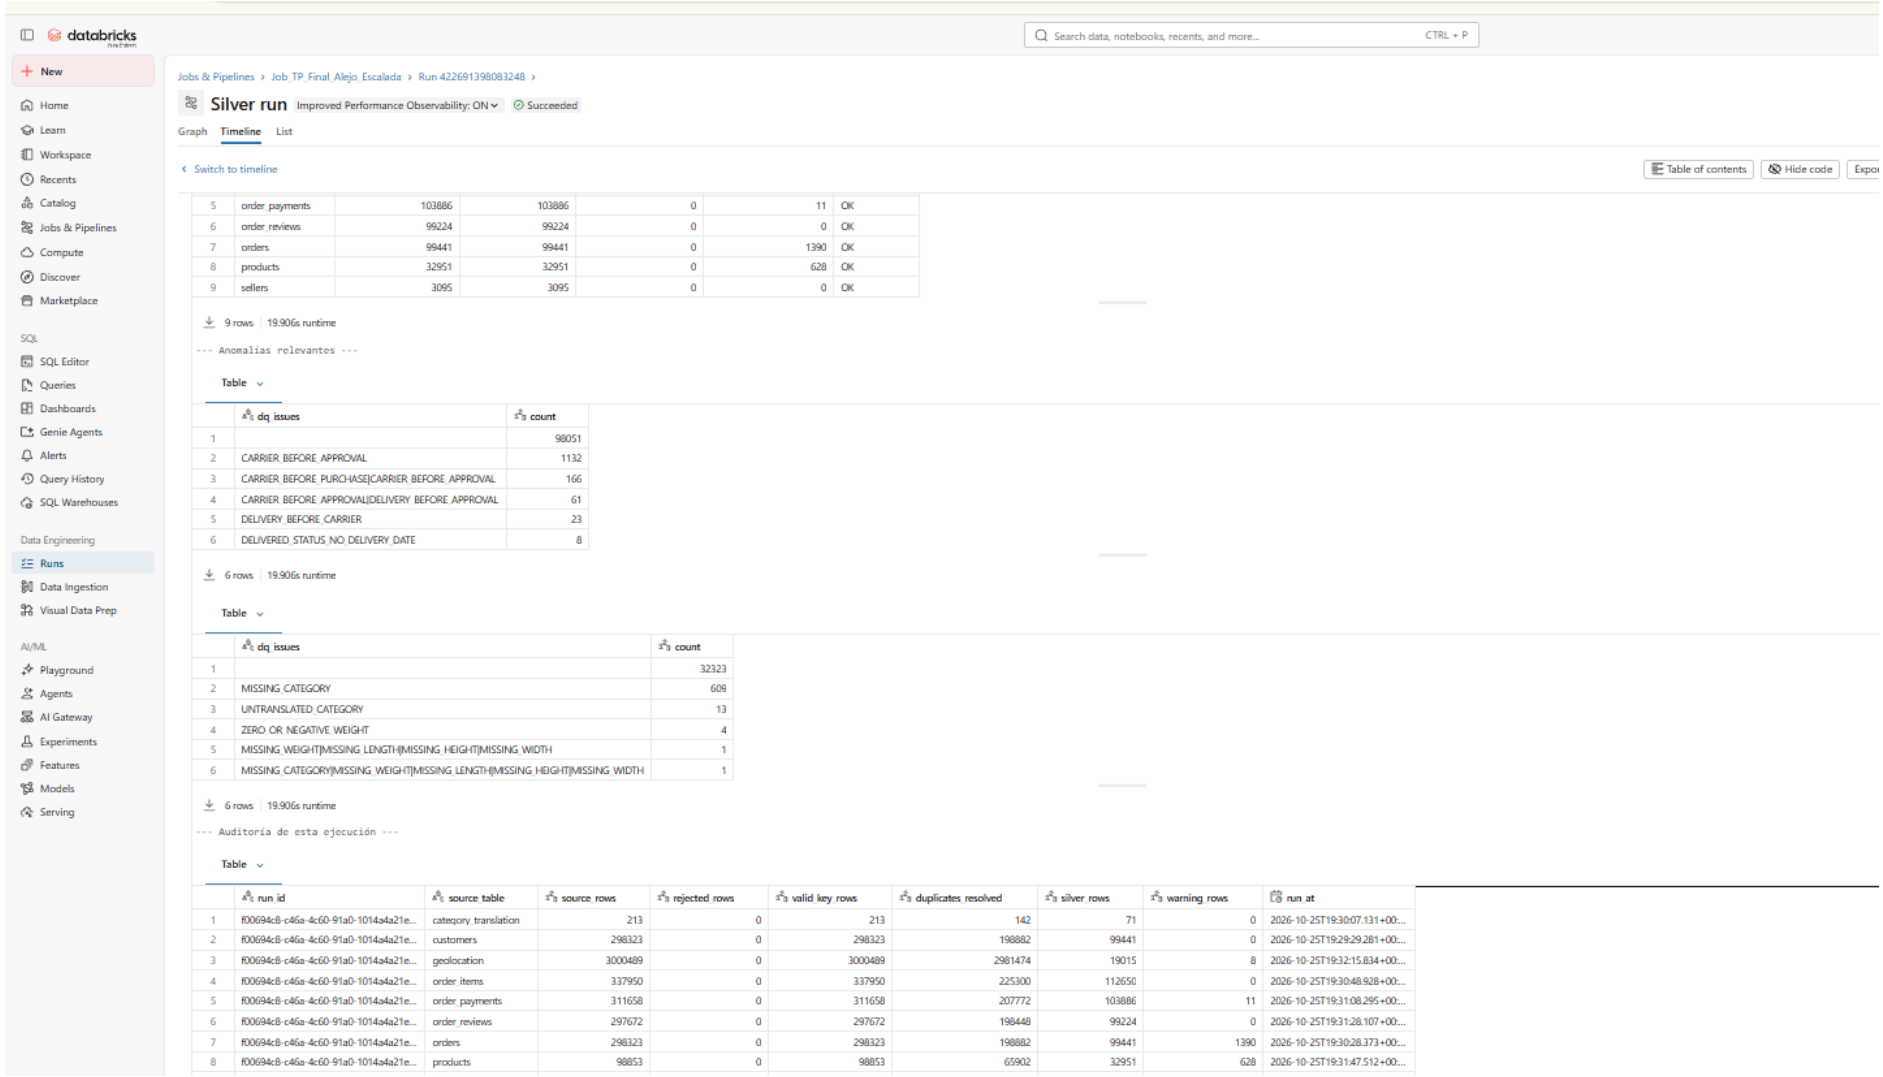
Dos capturas de timeline permiten comprobar el orden de ejecución y la finalización de las cuatro tareas del Job.





05 · Controles y auditoría de Silver

La ejecución de Silver presenta controles por entidad, anomalías de calidad y una auditoría con registros recibidos, claves válidas, duplicados resueltos y filas finales. Las anomalías identificadas se registran para su seguimiento.



5	order_payments	103886	103886	0	11	OK
6	order_reviews	99224	99224	0	0	OK
7	orders	99441	99441	0	1390	OK
8	products	32951	32951	0	628	OK
9	sellers	3095	3095	0	0	OK

9 rows | 19.906s runtime

--- Anomalías relevantes ---

Table

	dq_issues	count
1		98051
2	CARRIER_BEFORE_APPROVAL	1132
3	CARRIER_BEFORE_PURCHASE|CARRIER_BEFORE_APPROVAL	166
4	CARRIER_BEFORE_APPROVAL|DELIVERY_BEFORE_APPROVAL	61
5	DELIVERY_BEFORE_CARRIER	23
6	DELIVERED_STATUS_NO_DELIVERY_DATE	8

6 rows | 19.906s runtime

Table

	dq_issues	count
1		32323
2	MISSING_CATEGORY	609
3	UNTRANSLATED_CATEGORY	13
4	ZERO_OR_NEGATIVE_WEIGHT	4
5	MISSING_WEIGHT|MISSING_LENGTH|MISSING_HEIGHT|MISSING_WIDTH	1
6	MISSING_CATEGORY|MISSING_WEIGHT|MISSING_LENGTH|MISSING_HEIGHT|MISSING_WIDTH	1

6 rows | 19.906s runtime

--- Auditoría de esta ejecución ---

Table

	run_id	source_table	source_rows	rejected_rows	valid_key_rows	duplicates_resolved	silver_rows	warning_rows	run_at
1	f00694c8-c46a-4c60-91a0-1014a4a21e...	category_translation	213	0	213	142	71	0	2026-10-25T19:30:07.131+00:...
2	f00694c8-c46a-4c60-91a0-1014a4a21e...	customers	298323	0	298323	198882	99441	0	2026-10-25T19:29:29.281+00:...
3	f00694c8-c46a-4c60-91a0-1014a4a21e...	geolocation	3000489	0	3000489	2981474	19015	8	2026-10-25T19:32:15.834+00:...
4	f00694c8-c46a-4c60-91a0-1014a4a21e...	order_items	337950	0	337950	225300	112650	0	2026-10-25T19:30:48.928+00:...
5	f00694c8-c46a-4c60-91a0-1014a4a21e...	order_payments	311658	0	311658	207772	103886	11	2026-10-25T19:31:08.295+00:...
6	f00694c8-c46a-4c60-91a0-1014a4a21e...	order_reviews	297672	0	297672	198448	99224	0	2026-10-25T19:31:28.107+00:...
7	f00694c8-c46a-4c60-91a0-1014a4a21e...	orders	298323	0	298323	198882	99441	1390	2026-10-25T19:30:28.373+00:...
8	f00694c8-c46a-4c60-91a0-1014a4a21e...	products	98853	0	98853	65902	32951	628	2026-10-25T19:31:47.512+00:...

06 · Auditoría de idempotencia

La tabla **pipeline_run_audit** muestra una ejecución en modo **auto** con **idempotence_compared = true** e **idempotence_passed = true**. En esa ejecución figuran 4.652.766 filas Bronze, 569.774 Silver y 13.867 Gold, con cero controles fallidos.



	run_id	job_run_id	mode	baseline_run_id	recorded_at	bronze_rows	silver_rows	gold_rows	silver_warning_rows	silver_rejected_rows	gmv_total_brl	checks_total	checks_failed	idempotence_compared	idempoten
1	0e605f32-3f9c-496e-9b4c-aaaa89842467	interactive	auto	577358cb-e039-45a0-bf9b-04fdbbff61...	2026-10-25T19:58:24.790+00:...	4652766	569774	13867	2037	0	13221498.11	167	0	true	true
2	577358cb-e039-45a0-bf9b-04fdbbff614d	interactive	baseline	null	2026-10-25T19:36:58.813+00:...	4652766	569774	13867	2037	0	13221498.11	162	0	false	null
3	05c975d4-c85e-4219-8fb7-3bb51cb73113	interactive	baseline	null	2026-10-25T19:12:14.774+00:...	3101844	569774	13867	2037	0	13221498.11	162	0	false	null
4	bb7b3e65-de31-4ee8-9086-2efd0640eb...	interactive	baseline	null	2026-10-25T18:02:05.983+00:...	1550922	569774	13867	2037	0	13221498.11	160	0	false	null

Nota: esta captura registra el resultado de la comparación automática; el identificador del batch de Bronze se consulta por separado en la auditoría de Silver.

07 · Gold: evolución mensual de ventas

Visualización generada a partir de **gold_monthly_sales**. El gráfico muestra la evolución mensual del GMV de artículos expresado en reales brasileños (BRL). No incluye fletes.

1. Evolución mensual de ventas — `gold_monthly_sales`

Qué muestra: cómo cambia el GMV de artículos en BRL mes a mes. No incluye fletes, por lo que no representa el total cobrado.

```
fig = go.Figure()
fig.add_trace(go.Scatter(x=sales["mes"], y=sales["gmv_brl"].astype(float), mode="lines+markers",
    line=dict(color=BLUE,width=3), marker=dict(size=7), fill="tozeroy", fillcolor="rgba(37,99,235,0.08)",
    name="GMV", hovertemplate="%{x|%b %Y}: R$ %{y:,.0f}<extra></extra>"))
polish(fig, "Ingresos comerciales por mes (GMV)")
fig.update_yaxes(title_text="BRL",tickprefix="R$ ",tickformat="~s")
fig.show()
```



08 · Gold: categorías líderes

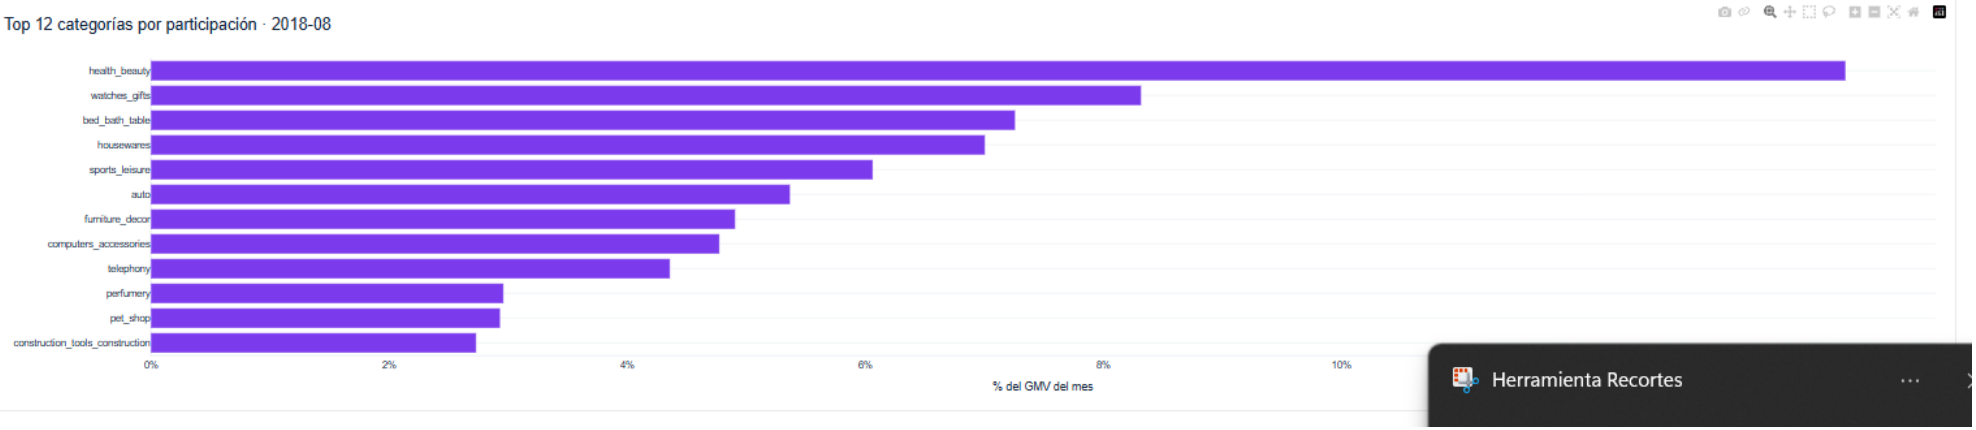
Visualización generada a partir de **gold_monthly_category_share**. Muestra las doce categorías con mayor participación en el GMV de agosto de 2018. La métrica se basa en el precio de los artículos, sin flete.

3. Categorías líderes en el mes — `gold_monthly_category_share`

Qué muestra: las categorías de mayor participación en el GMV del mes elegido. La cuota utiliza precios de ítems, sin flete.

```
cc = month_only(cat).sort_values("gmv_brl", ascending=False).head(12)
if cc.empty: print("Sin categorías para", MES)
else:
    cc=cc.sort_values("participacion_gmv_pct")
    fig=go.Figure(go.Bar(y=cc["categoria_analitica"],x=cc["participacion_gmv_pct"].astype(float),
        orientation="h", marker_color=PURPLE,
        customdata=cc["gmv_brl"].astype(float),
        hovertemplate="%{y}: %{x:.2f}% · R$ %{customdata:,.0f}<extra></extra>"))
    polish(fig, f"Top 12 categorías por participación · {MES}", height=490)
    fig.update_xaxes(title_text="% del GMV del mes",ticksuffix="%")
    fig.show()
```

cc: pandas.core.frame.DataFrame = [mes: datetime64[ns], categoria_analitica: object ... 7 more fields]



Herramienta Recortes

09 · Síntesis de resultados

Arquitectura: esquema Lakehouse con capas Bronze, Silver y Gold y un Job de cuatro tareas encadenadas.

Ejecución: el historial registra dos ejecuciones exitosas y los timelines muestran la secuencia operativa.

Calidad: Silver produce controles, auditorías y registro de anomalías; los resultados permiten inspeccionar el tratamiento de duplicados.

Idempotencia: la auditoría automática registra comparación aprobada, sin controles fallidos en la ejecución mostrada.

Consumo analítico: se muestran productos Gold para ventas mensuales y participación por categoría.

Documento elaborado exclusivamente con las capturas aportadas del entorno Databricks.