TRABAJO PRÁCTICO / OPCIÓN A

Del dato crudo al dato útil

Arquitectura Medallion en Databricks con datos de Olist



Informe explicativo en lenguaje claro: qué datos usamos, cómo los procesamos, qué controles hicimos y qué resultados obtuvimos.

Fecha de referencia: 25 de octubre de 2026.

Idea principal La primera capa guarda lo recibido; la segunda quita duplicados y ordena; la tercera convierte esos datos en información para analizar ventas y entregas.

1. Qué queríamos resolver

Una empresa puede tener datos de ventas, clientes, productos y pagos en distintos archivos. El problema aparece cuando queremos analizar todo junto: puede haber formatos diferentes, datos incompletos o registros repetidos. Si sumamos todo sin limpiar, los indicadores pueden quedar mal.

Nuestro objetivo fue construir un recorrido confiable: recibir datos originales, limpiarlos sin perder trazabilidad y generar tablas listas para responder preguntas de negocio.

2. De dónde salen los datos

Utilizamos Olist, un conjunto histórico de comercio electrónico de Brasil. Lo elegimos porque reúne distintas partes de una compra y permite estudiar resultados comerciales y problemas de entrega. No son datos en tiempo real.

Archivo / tema	Qué contiene
Clientes	Datos del cliente y su ubicación.
Pedidos	Qué se compró, estado y fechas del pedido.
Artículos del pedido	Qué productos integran cada compra, cantidades e importes.
Pagos	Cómo y cuánto se pagó.
Productos	Información de los productos y su categoría.
Vendedores	Datos de quienes venden.
Reseñas	Opiniones y calificaciones posteriores a la compra.
Geolocalización	Referencias geográficas asociadas a códigos postales.
Traducción de categorías	Nombre de categorías en portugués e inglés.

Los nueve CSV se leen desde el volumen de archivos de Databricks: /Volumes/workspace/olist_lakehouse/raw_data/. Inicialmente sumaban 1.550.922 filas entre todos los archivos.

Ejemplo simple Un pedido puede tener varios productos y más de un pago. Por eso no se deben sumar esas tablas sin entender cómo se relacionan: podríamos contar una venta varias veces.

3. Cómo funciona el recorrido de los datos

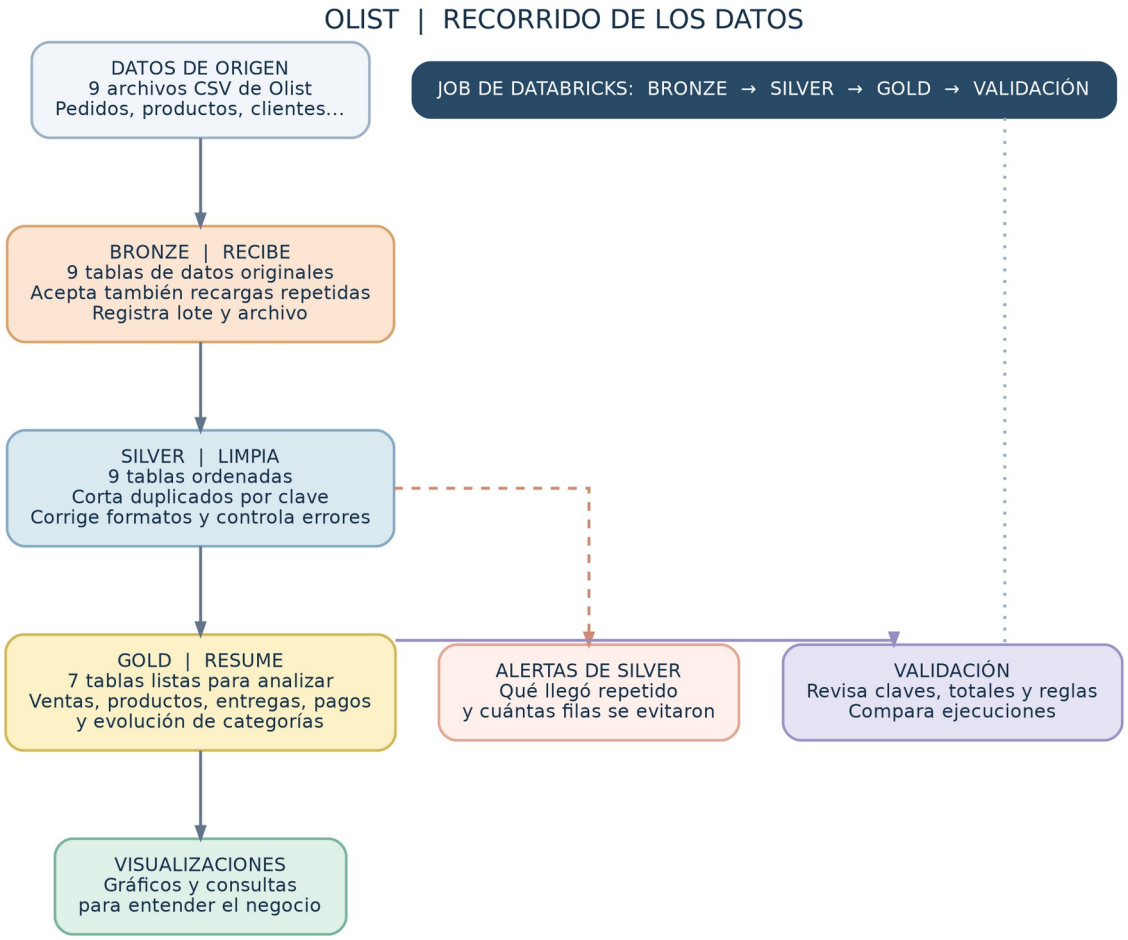


Diagrama 1. El camino desde los archivos originales hasta los gráficos y controles.

Bronze es la bandeja de entrada: guarda lo que llegó, incluso si ya lo habíamos recibido. También registra de qué archivo y de qué carga proviene.

Silver es el filtro: identifica registros repetidos por sus claves, conserva una única versión, corrige formatos y marca problemas de calidad.

Gold es el resumen útil: toma únicamente los datos de Silver para calcular ventas, rankings, entregas, pagos y evolución de categorías.

El Job de Databricks ejecuta las etapas en orden: Bronze → Silver → Gold → Validación. Si una etapa falla, la siguiente no debe continuar como si nada.

4. Cómo se conectan las tablas

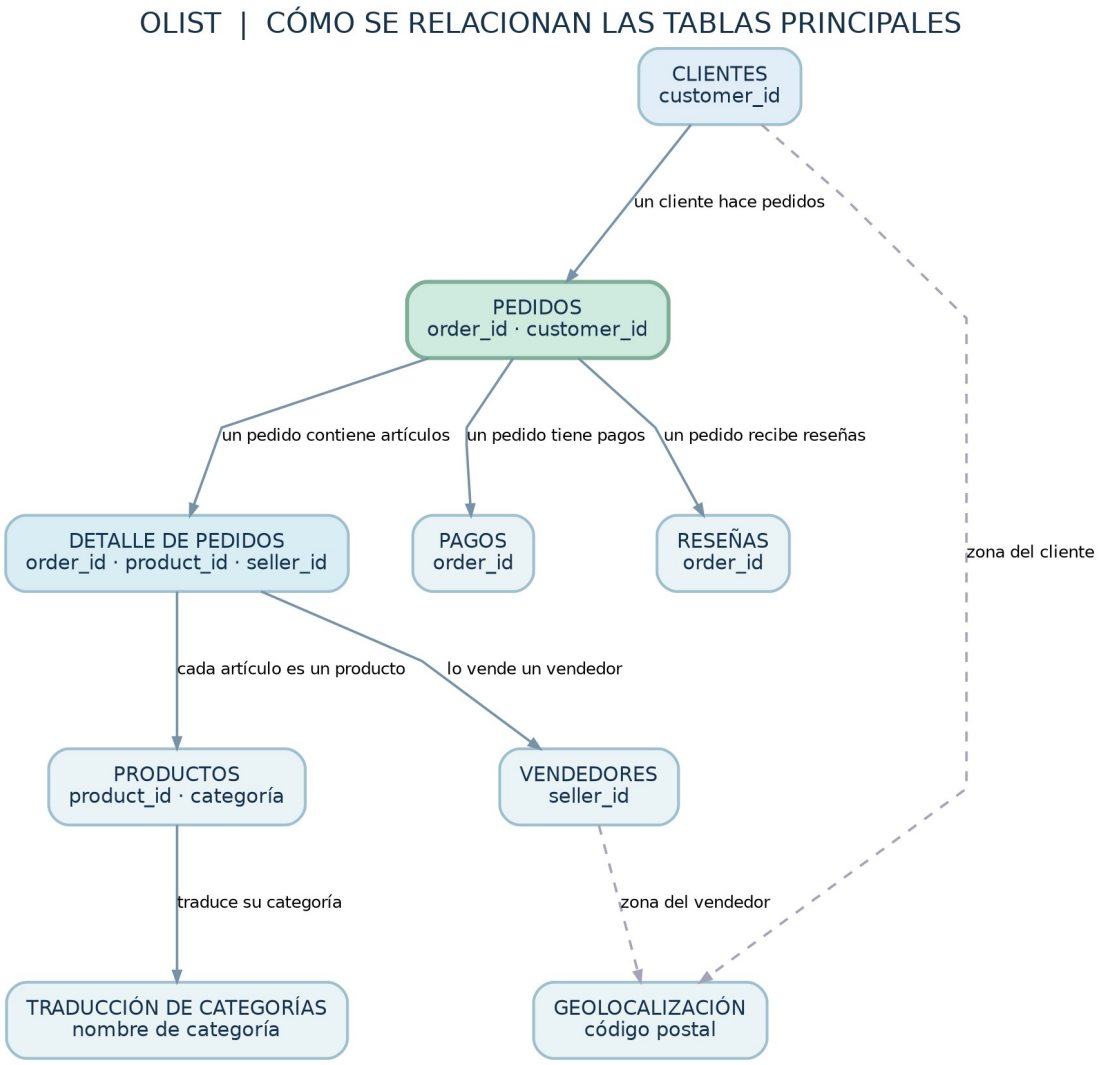


Diagrama 2. Relaciones principales entre los datos de Olist; no es un inventario de todas las columnas.

Ejemplo de lectura: un cliente hace un pedido; el pedido contiene artículos; cada artículo corresponde a un producto y a un vendedor. El mismo pedido también puede tener pagos y reseñas.

La información de categorías sirve para agrupar productos. La geolocalización ayuda a ubicar clientes y vendedores por código postal.

Decisión importante No se juntó todo en una tabla gigante. Se mantuvieron distintas tablas porque cada una responde a una pregunta y tiene su propia clave. Así reducimos el riesgo de repetir importes al cruzar información.

5. Lo más importante: Silver corta los duplicados

Queríamos probar un caso concreto: cargar nuevamente los mismos archivos y comprobar que Bronze los recibiera, pero que Silver no repitiera las ventas ni alterara los resultados de Gold.

Momento	Bronze	Silver	Gold
Primera carga	1.550.922 filas	569.774 filas	13.867 filas
Recarga idéntica	3.101.844 filas	569.774 filas	13.867 filas

En la segunda carga, Bronze agregó otras 1.550.922 filas. Silver identificó esas repeticiones y dejó registradas alertas. Las nueve tablas Silver conservaron su tamaño original.

Qué se registró en la auditoría de duplicados

Indicador	Resultado de la recarga
Registros recibidos en el lote	1.550.922
Coincidencias exactas registradas	1.550.922
Claves nuevas	0
Versiones con datos distintos para la misma clave	0
De esas coincidencias: geolocalización	1.000.163 (tratadas como información geográfica)

La auditoría distingue la geolocalización de las tablas comerciales, porque puede haber varias observaciones asociadas a un mismo código postal. No corresponde tratar todas esas observaciones como ventas duplicadas.

Qué significa “cortar” El duplicado puede existir en Bronze, pero no se incorpora como una segunda fila de negocio en la tabla Silver final. Además, queda una señal de que esa repetición ocurrió.

6. Qué información construimos en Gold

Gold reúne siete tablas finales, cada una pensada para una pregunta concreta. Así, no hace falta recorrer los nueve archivos originales cada vez que queremos mirar el negocio.

Tabla Gold	Qué permite ver
gold_monthly_sales	Ventas por mes, unidades vendidas y ticket promedio.
gold_monthly_category_share	Qué parte de las ventas aporta cada categoría.
gold_monthly_top_products	Cuáles fueron los productos más vendidos cada mes.
gold_monthly_category_state	Cómo se distribuyen categorías y ventas por estado.
gold_delivery_performance	Si los pedidos llegaron a tiempo y en qué zonas hubo más demoras.
gold_monthly_payment_methods	Cuánto representa cada medio de pago.
gold_monthly_portfolio_evolution	Si el negocio depende de pocas categorías o está más diversificado.

Cómo leer los importes sin confundirlos

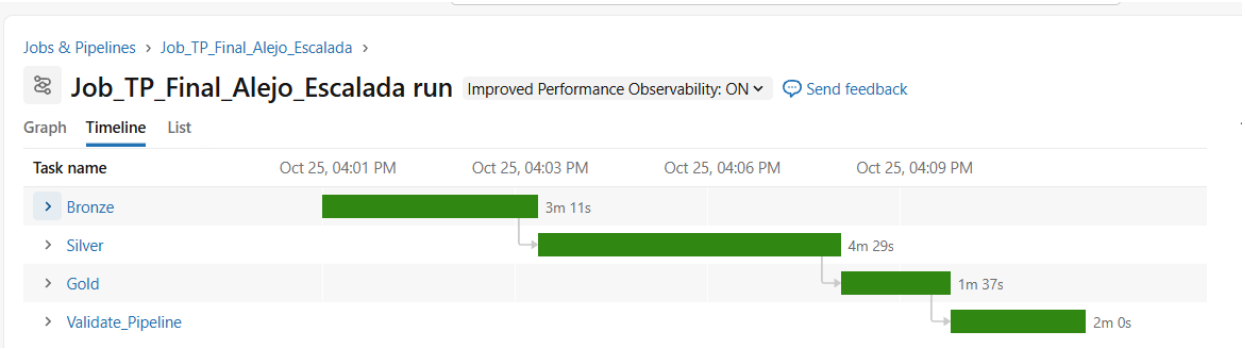
En este proyecto usamos GMV como el valor de los productos vendidos en pedidos entregados, sin sumar el costo de envío. Por eso no es exactamente lo mismo que el total de pagos ni que la facturación contable de una empresa.

El notebook 05_visualizaciones_gold está preparado para mostrar gráficos de estas siete tablas con una explicación corta en cada sección. Su ejecución visual en Databricks todavía debe revisarse antes de incorporarla como evidencia final.

> **Ejemplo de utilidad** Si una categoría aumenta su participación en las ventas, el negocio puede decidir prestarle más atención. Si en cierto estado hay más demoras de entrega, puede investigar su logística.

7. Cómo se ejecutó todo: el Job

Creamos un Job con cuatro tareas dependientes. Cada tarea comienza después de que la anterior termina con éxito.



Evidencia del Job: Bronze, Silver, Gold y Validación terminaron en verde (25/10/2026).

Tarea	Duración observada	Resultado
Bronze	3 min 11 s	Correcto
Silver	4 min 29 s	Correcto
Gold	1 min 37 s	Correcto
Validate_Pipeline	2 min	Correcto

Duración total aproximada: 11 minutos y 17 segundos. La ejecución se realizó de principio a fin sin saltarse etapas.

Los resultados quedan registrados en tablas de auditoría. Esto permite revisar qué ocurrió en cada corrida, no solo mirar si el Job aparece en verde.

8. Qué resultados pudimos comprobar

Qué medimos	Primera ejecución	Luego de recargar
Total Bronze	1.550.922	3.101.844
Total Silver	569.774	569.774
Total Gold	13.867	13.867
GMV de ventas (BRL)	13.221.498,11	13.221.498,11
Controles fallidos	0	0

Estos números muestran que repetir los datos de origen no duplicó los registros finales de Silver y Gold. También muestran que el valor total de ventas calculado en Gold permaneció igual.

Controles de calidad

- Se comprueba que las claves importantes no estén vacías y que las tablas finales no repitan claves de negocio.
- Se controla que pedidos, clientes, productos y pagos puedan relacionarse correctamente.
- Se comparan cantidades e importes entre las etapas para detectar diferencias inesperadas.
- La primera validación registró 2.037 advertencias y ningún rechazo; una advertencia no implica necesariamente eliminar una fila.

Qué todavía no hay que afirmar

La recarga idéntica ya fue probada con resultados reales. En cambio, la última variante del validador automático, que decide sola contra qué ejecución comparar, todavía no tiene una corrida confirmada en estas evidencias. Tampoco se probó aquí un lote nuevo con ventas diferentes.

> **Alcance de la prueba** Podemos afirmar que Silver eliminó duplicados exactos y que Gold no se infló en la recarga observada. La comparación automática de fingerprints y el caso de ventas verdaderamente nuevas son comprobaciones adicionales.

9. Por qué tomamos estas decisiones

Decisión	Explicación simple
Mantener tres capas	Evita mezclar datos originales con datos ya preparados.
Aceptar recargas en Bronze	Podemos conservar lo recibido y detectar repeticiones más adelante.
Cortar duplicados en Silver	No queremos vender dos veces en los indicadores la misma compra.
Guardar alertas	Permite saber qué pasó sin tener que adivinarlo.
Calcular Gold a partir de Silver	Los gráficos consumen datos depurados y consistentes.
Orquestar con un Job	Las tareas corren en el orden correcto, con trazabilidad.
Validar antes de cerrar	Un Job verde es necesario, pero también hacen falta cifras correctas.

10. Consigna: comprobación final

Punto pedido	Dónde se muestra
1. Origen, descripción y elección	Secciones 1 y 2.
2. Ingesta, limpieza y al menos un Gold	Secciones 3, 5 y 6; notebooks 01 a 03.
3. Orden y resultado del Job	Sección 7; captura de ejecución completa.
4. Modelado y decisiones	Secciones 4 y 9; diagramas.
5. Consultas o visualizaciones	Notebook 05 preparado; falta guardar capturas de su ejecución.

Conclusión

Construimos un proceso completo que recibe datos de Olist, identifica repeticiones, limpia las tablas y prepara indicadores comerciales. La prueba más clara fue duplicar la carga de Bronze: Silver conservó las mismas 569.774 filas y Gold mantuvo R$ 13.221.498,11 de GMV. La arquitectura quedó orquestada y validada con una ejecución completa en Databricks.

Para terminar la entrega, solo queda ejecutar y capturar las visualizaciones del notebook 05 y confirmar, si se desea presentar, el funcionamiento del nuevo modo de validación automática.